

第五次作业实验报告

BBOPlace-Bench 算子实验与分析

PS: 我对框架代码提了两份 PR

具体请看[这个部分](#) ✓

南京大学匡亚明学院

罗嘉恒

241240049

2026 年 7 月 25 日

目录

1 Task 1: 交叉与变异算子研究	3
1.1 实验配置	3
1.2 实验结果	3
1.2.1 最终性能	3
1.2.2 收敛过程	5
1.2.3 分布指数敏感性	7
1.3 实验分析	8
1.3.1 Crossover-mutation interaction	8
1.3.2 为什么 Uniform + Swap 会表现良好	8
2 Task 2: 多目标优化	9
2.1 实验配置	9
2.2 实验结果	10
2.2.1 最终 Pareto 前沿质量	10
2.2.2 Hypervolume 收敛过程	11
2.2.3 最终种群与 phenotype diversity	11
2.3 实验分析	12
2.3.1 第二目标是否提供有效的权衡信号	12
2.3.2 Phenotype redundancy 与 MOEA/D collapse	13
2.3.3 Uniform + Swap 的实际扰动及其后果	14
2.3.4 与 Task 1 参考结果的比较	15
2.3.5 对 Task 3 的启示	15
3 Task 3: 改进算法	17
3.1 结果分析	17
4 实验框架捉 bug	18
4.1 Bug 1: MGO net traversal 非确定性	18
4.2 Bug 2: 初始化 population 被重复评价	18
4.3 Bug 3: Swap mutation 的高级索引错误	18
4.4 Bug 4: DummyMutation 初始化与约束字段标记	18
5 附录	19
5.1 Task 1 运行与复现	19
5.2 Task 2 运行与复现	19
5.3 Task 3 运行结果、复现方法与运行时间	20

1 Task 1: 交叉与变异算子研究

1.1 实验配置

Task 1 的目标是在固定的 MGO 表示、单目标 MP-HPWL 评价和严格相同的评价预算下，比较不同交叉算子与变异算子的搜索行为。实验采用两个交叉算子 (Uniform、SBX) 和五个变异算子 (Swap、Shift、Random Resetting、Shuffle、Polynomial Mutation)，形成 2×5 的完整析因设计。

项目	固定设置
Benchmark	ISPD 2005 adaptec1, 512 macros(非全维度)
Placement representation	MGO, 224×224 grid, rank_key = area_sum
Population	20; 每代最多产生 20 个 offspring
Initialization	每个 seed 随机产生 20 个 genotype, 也就是 n_sampling_repeat = 1
Budget	每个 run 严格 10,000 次真实 objective evaluation
Selection / survival	Binary tournament; $(\mu + \lambda)$ elitist fitness survival
Crossover	Uniform/SBX; 总体概率均为 1.0
Mutation	Swap/Shift/Random Resetting/Shuffle/PM
Randomness	seeds 1-5; 同一 seed 在所有配置中使用相同初始 population
Duplicate handling	删除重复 genotype
Replicates (第一类实验)	Crossover $\times$ Mutation $\times$ 5 seeds = 50 runs
Sensitivity (第二类实验)	SBX $\eta \in \{5, 15, 30\}$ 与 PM $\eta \in \{5, 15, 30\}$, 共 20 runs
Total	70 runs, 700,000 次真实 objective evaluation

其中:

- Uniform crossover 的变量交换概率为 0.5
- SBX 使用 prob_var = 0.5、prob_exch = 1.0、prob_bin = 0.5
- $\eta = 30$ 。
- PM 的个体级概率和变量级概率均为 1.0

1.2 实验结果

1.2.1 最终性能

备注: 主文中的标准差采用原仓库结果汇总代码 np.std 的口径, 即 population standard deviation (ddof = 0)。ddof = 1 的 sample standard deviation 单独保留在审计 CSV 中。对 5 个 seeds, 后者固定比前者大 $\sqrt{\frac{5}{4}} \approx 1.118$ 倍; 统一口径后, 各配置的 coefficient of variation 为 0.50%-1.75%, 与论文中的 Vanilla EA 的标准差是相近的。

表 Table 1 给出 evaluation 10,000 时的最终 best-so-far HPWL。数值均以 10^5 为单位, 标准差为 ddof = 0。

Rank	Configuration	Mean $\pm$ Std	Median	Best	Worst
1	Uniform + Swap (Baldwinian)	5.7671 $\pm$ 0.0592	5.7819	5.6759	5.8275
2	Uniform + Swap (Lamarckian)	(BLANCK)	(BLANCK)	(BLANCK)	(BLANCK)
3	Uniform + Random Resetting	5.7809 $\pm$ 0.0595	5.7856	5.6756	5.8603
4	SBX + Shuffle	5.7845 $\pm$ 0.0565	5.7715	5.6984	5.8689
5	Uniform + Shuffle	5.7864 $\pm$ 0.0457	5.7826	5.7376	5.8700
6	SBX + PM	5.8059 $\pm$ 0.0390	5.7863	5.7724	5.8794
7	Uniform + PM	5.8139 $\pm$ 0.0291	5.8037	5.7874	5.8685
8	SBX + Swap	5.8301 $\pm$ 0.0845	5.8020	5.7412	5.9773
9	SBX + Random Resetting	5.8689 $\pm$ 0.1027	5.8190	5.7651	6.0520
10	Uniform + Shift	5.9753 $\pm$ 0.0626	5.9615	5.9075	6.0649
11	SBX + Shift	6.0091 $\pm$ 0.0466	6.0101	5.9370	6.0693

Table 1: 十种算子组合的最终 HPWL ($\times 10^5$, 5 seeds, population std)。




Figure 1: 两种 crossover 与五种 mutation 的最终 HPWL。
单元格为 mean ± population std, 越低越好。




Figure 2: 五个 seeds 的最终 HPWL 分布。
菱形为均值, 横线为中位数, 散点为单个 seed。

图 Figure 2 进一步说明均值排名对 seed 有一定敏感性。单次运行的全局最低值来自 Uniform + Random Resetting、seed 3, HPWL 为 5.6756×10^5 ; 它只比同 seed 的 Uniform + Swap 低约 31.4, 因此不能用单次最好结果替代跨 seed 平均。按每个 seed 内的 rank 再取平均, SBX + Shuffle 为 3.20, Uniform + Swap 为 3.60, Uniform + Shuffle 和 Uniform + Random Resetting 均为 3.80。

十种配置的 Friedman test 得到 $\chi^2 = 23.967$ 、 $p = 0.004353$, 说明整体配置效应可检测; 但仅有 5 个 paired seeds, 前四名之间的精确配对检验均没有提供强证据。两个 Shift 组合相对 Uniform + Swap 在 5/5 seeds 上均更差, 但双侧 exact sign-flip test 在 $n = 5$ 时最小只能达到 $p = 0.0625$, 因此报告中同时给出方向一致性与样本量限制。

相对改进率定义为

$$\frac{\text{best_at_20} - \text{best_at_10000}}{\text{best_at_20}} \times 100\%$$

表 Table 2 给出每个 seed 的配对结果。

Configuration	S1	S2	S3	S4	S5	Mean
Uniform + Swap	13.640	14.357	13.285	9.936	11.652	12.574
Uniform + Random Resetting	12.710	13.874	13.290	10.370	11.600	12.369
SBX + Shuffle	12.923	14.525	12.941	10.839	10.322	12.310
Uniform + Shuffle	12.677	15.678	12.097	10.607	10.305	12.273
SBX + PM	12.793	13.593	11.598	10.169	11.796	11.990
Uniform + PM	12.240	13.753	11.333	10.533	11.483	11.868
SBX + Swap	11.518	15.625	11.915	10.308	8.666	11.606
SBX + Random Resetting	12.207	14.737	7.540	10.878	9.745	11.021
Uniform + Shift	9.032	12.387	9.661	8.677	7.327	9.417
SBX + Shift	9.734	10.804	7.629	8.220	8.164	8.910

Table 2: 从 initial population best 到 evaluation 10,000 best 的逐 seed 相对改进率 (%)。

与原论文结果的对照: 原 [BBOPlace-Bench](#) 的 MGO Vanilla-EA 配置对应 Uniform + Shuffle, 并使用 population 50、n_sampling_repeat = 5。其 adaptec1 报告值约为 $5.80 \pm 0.03 \times 10^5$ 。本实验冻结协议下的对应组合为 $5.7864 \pm 0.0457 \times 10^5$: 平均值接近, 但标准差略高。该差异不能直接归因于实现错误, 因为本实验主动将 population 降为 20, 并取消了从 50×5 个初始候选中筛选最优 50 个的重复采样过程; 两项改变都会增加早期搜索路径对 seed 的敏感性。所以可以认为我们复现了论文对 VanillaEA 的结果。

1.2.2 收敛过程

所有收敛图均以真实 objective evaluation 为横轴, 每 20 次评价取一个已有 best-so-far 数据点。实线为 5-seed mean, 阴影为 population std (ddof = 0)。




Figure 3: Uniform crossover 下五种 mutation 的收敛曲线。




Figure 4: SBX crossover 下五种 mutation 的收敛曲线。

Uniform + Swap 在 evaluation 1,000、5,000 和 10,000 的平均 HPWL 均为第一。其平均改进可分解为: evaluation 20-1,000 改进 70,718, 1,000-5,000 改进 10,222, 5,000-10,000 仅再改进 2,177; 约在 evaluation 1,940 达到其最终总改进的 90%。这说明它的优势主要来自早期快速找到高质量结构, 而非依赖很长的后期搜索。

Uniform + Random Resetting 的早期表现较弱, 但 evaluation 5,000 后仍改进约 6,798, 明显高于 Uniform + Swap 的 2,177。该现象与 Random Resetting 能持续引入全新 guide coordinates 的机制一致, 但其跨 seed 结果也更不稳定。Shift 很早达到“自身最终改进”的 90%, 却停在明显更差的平台; 因此它的短 time-to-90% 不是高效收敛, 而是过早停滞。

1.2.3 分布指数敏感性

SBX distribution index sensitivity with Swap mutation




Figure 5: SBX + Swap 的分布指数 η 敏感性。

SBX + Swap 的最终结果为: $\eta = 5$ 时 5.8027 ± 0.0491 , $\eta = 15$ 时 5.8111 ± 0.0723 , $\eta = 30$ 时 5.8301 ± 0.0845 。较小 η 的平均值更好, 但是并不是非常的敏感。

Polynomial-mutation distribution index sensitivity with Uniform crossover




Figure 6: Uniform + PM 的分布指数 η 敏感性。

Uniform + PM 的结果为: $\eta = 5$ 时 5.8769 ± 0.0294 , $\eta = 15$ 时 5.8140 ± 0.0277 , $\eta = 30$ 时 5.8139 ± 0.0291 。 $\eta = 15$ 与 30 基本相同, 而 $\eta = 5$ 在 5/5 seeds 上都更差。由于本协议设置 $\text{pm_prob_var} = 1.0$, PM 会尝试扰动全部标量坐标; 较小 η 进一步扩大扰动尺度, 因而更容易破坏已有的优良结构。这一机制解释与数据高度一致。

1.3 实验分析

1.3.1 Crossover-mutation interaction



Figure 7: evaluation 10,000 时的 crossover-mutation interaction。误差条为 population std。

跨两个 crossover 汇总后，mutation 的边际均值从好到差为 Shuffle、Swap、PM、Random Resetting、Shift；但该顺序不能完整表达交互关系。Uniform 的总体边际均值低于 SBX，然而 SBX 与 Shuffle、PM 搭配时略好，Uniform 与 Swap、Random Resetting、Shift 搭配时平均更好。图 Figure 7 中两条折线并不平行，这正是交互效应的直接表现。

1.3.2 为什么 Uniform + Swap 会表现良好

我在实验前有个预期，认为 Swap 不产生新坐标，因此探索不足，应该不会产生很好的结果。结果与我的判断相反。对此我的理解是，初始种群虽然只包含有限数量的 genotype，但可能已经提供了足够丰富的 guide-coordinate building blocks，并覆盖了多个有潜力的 MGO decoding basins。Uniform crossover 通过重新组合坐标分量，Swap mutation 通过重新分配宏与坐标对之间的对应关系，在不持续引入高破坏性新坐标的情况下形成了较大的组合搜索空间。因此，Uniform + Swap 能够更快地利用已有优质区域。相比之下，持续生成新坐标的算子虽然维持了更广的探索，但也会将更多评价预算用于进入新的或低质量的 decoding basins，从而减慢收敛并增加结果波动。

还有如下一些结论：

1. 在冻结的 adaptec1/MGO 协议下，Uniform + Swap 的平均最终 HPWL 与 mean convergence AUC 最好，可作为后续实验的 reference configuration。
2. Uniform + Random Resetting、SBX + Shuffle 和 Uniform + Shuffle 与其差距较小；前四名应视为统计上尚未解析的竞争组，而非确定的严格排序。
3. Shift 是最清晰的负面结果：无论与 Uniform 还是 SBX 搭配，都较早停在明显更差的平台。
4. Crossover 与 mutation 存在显著交互，不能脱离 mutation 单独宣称某一种 crossover 普遍更优。
5. “是否产生新坐标值”不足以预测 MGO 上的算子表现；guide-coordinate genotype 与 greedy legal phenotype 之间的非线性映射是解释结果的关键。
6. PM 在全变量变异设置下不适合过小的 η ；SBX 的 η 敏感性则需要更多 seeds 才能形成强结论。

2 Task 2: 多目标优化

Task 1 在统一的 MGO 表示与评价预算下比较了不同交叉、变异算子组合，并将 Uniform + Swap 选为后续实验的 reference configuration。它在最终 HPWL 和收敛速度上表现较好，但现有结果仍不足以解释这种优势从何而来。MGO 的 genotype 只表示宏的 guide coordinates，greedy decoder 才决定最终 placement；不同 genotype 可能落入同一个 decoding basin，也可能经过幅度相近的扰动后产生完全不同的布局。Shift 较早停在较差平台的现象，也提示 genotype 层面的变化强度无法直接代表 phenotype 层面的有效探索。

此外，Task 1 的单目标评价只按照 HPWL 选择个体，因此无法观察布局在连线长度与局部布线热点之间的权衡。若直接进入 Task 3 设计新的算子或 decoder-aware 机制，我们仍缺少几类关键证据：Uniform + Swap 实际移动了多少宏、多少 offspring 被 decoder 映射回相同 phenotype、不同选择机制是否会导致 population diversity 或 MOEA/D weight slots 的集中，以及多目标搜索是否覆盖了 Task 1 未访问的低拥塞区域。

Task 2 延续 Task 1 的 top-512 macro 子问题、MGO 表示、Baldwinian 继承、初始化、population size、Uniform + Swap 和 10,000 次真实评价预算，并在每个 seed 内为 NSGA-II 与 MOEA/D 使用同一初始 population。实验将正式目标扩展为 HPWL 与 congestion_top10，同时记录 phenotype hash、父子关系、实际移动宏数、placement 位移、目标变化、population diversity 和 MOEA/D slot occupancy。这样的控制设计使两种多目标搜索机制成为主要差异，也为 Task 3 选择干预对象提供直接证据。

本 Task 主要回答三个问题：

1. 在相同初始化、表示、decoder、variation 和真实评价预算下，NSGA-II 与 MOEA/D 的 Pareto-front approximation 是否存在稳定差异？
2. congestion_top10 是否在高质量布局区域内提供区别于 HPWL 的有效权衡信号，多目标搜索是否扩展了现有 Task 1 参考解集？
3. 两种算法在 phenotype diversity、搜索冗余和 collapse 上有何差异，Uniform + Swap 的 genotype 扰动又有多少能够转化为有效的 placement 变化？

2.1 实验配置

Task 2 使用与 Task 1 相同的 top-512 macro 子问题。512 个节点由上游 benchmark reader 按面积降序稳定排序后截取；由于截断边界存在面积并列，实验同时冻结了原始 .nodes 顺序、节点名称、几何尺寸和 net topology 的 hash。当前 PlaceDB 含 512 个 macro 与 693 条 macro-level nets，所有正式 run 在评价开始前验证实际构造出的 PlaceDB 与协议一致。

正式目标为

$$F(X) = (\text{HPWL}(X), \text{Congestion}_{\text{top10}}(X)).$$

其中 HPWL 沿用 Task 1 的 cpu_comp_res evaluator。第二目标调用未修改的 DREAMPlace RUDY kernel，在 512×512 routing bins 上计算水平与垂直 demand，分别除以固定 unit capacity 1.5625 与 1.45，再取两个方向 utilization 的较大值；congestion_top10 是 utilization 最高的 10% bins 的算术均值。RUDY demand、total overflow、maximum overflow 与 overflow fraction 作为 auxiliary metrics 保存，不进入正式 objective vector。

congestion_top10 描述的是当前 macro-level netlist 上的 routing-utilization proxy。它没有执行 global routing，也没有放置 standard cells，因此本文不会将其解释为完整芯片的真实拥塞或 routability。

项目	固定设置
Benchmark	adaptedcl_upstream_native_top512_macro_subset; 512 macros, 693 nets
Representation / decoder	MGO, 224×224 grid, rank_key = area_sum; greedy decoder; Baldwinian
Formal objectives	MP-HPWL 与 congestion_top10
Population	20; 初始 population 20; 每个 seed 内两种算法共享相同生成顺序
Budget	每个 run 严格 10,000 次真实 objective evaluation
Variation	Uniform crossover + Swap mutation; 概率与 Task 1 完全相同
NSGA-II	rank/crowding tournament; nondominated sorting + crowding survival
MOEA/D	20 个均匀双目标 weight vectors; neighborhood size 10; normalized weighted Tchebycheff; 对所有改善的邻居执行 replacement

项目	固定设置
Duplicate handling	对完整已评价历史进行 genotype hash 排重；不删除 phenotype duplicate
Invalid decode	消耗评价预算；两个目标均返回 10^{16} ；不 repair、不 resample
Randomness	seeds 1-5；paired initialization；每个 run 使用独立随机状态与临时目录
Formal comparison	2 algorithms $\times$ 5 seeds = 10 runs，共 100,000 次真实评价
Backend	CPU；每 run 20 logical CPUs；RUDY 1 thread；最多 2 个并发 runs

Hypervolume 以最终 internal population 为 primary set，以累计 nondominated archive 为 secondary set。两个目标先使用固定 metric-audit bank 的上下界归一化：

$$z_j = \frac{f_j - l_j}{u_j - l_j},$$

其中 $l = (543427.75, 0.0087500)$ 、 $u = (1356135.19, 0.0261809)$ ，两端均包含 5% calibration margin。主 reference point 为 $(1.1, 1.1)$ ，并在 $(1.05, 1.05)$ 与 $(1.2, 1.2)$ 上检查 ordering sensitivity。正式结果没有参与 normalization bounds 的估计。

2.2 实验结果

2.2.1 最终 Pareto 前沿质量

与 Task 1 相同，本节表格和曲线中的标准差采用 population standard deviation (ddof = 0)。算法差异另外报告五个 paired seeds 的逐对差值、bootstrap confidence interval 和 exact Wilcoxon test。

Method	Final HV	Archive HV	Final ND phenotypes	Archive ND phenotypes	Valid eval/s	Decode failures
NSGA-II	1.1871 ± 0.0271	1.1871 ± 0.0271	19.4 ± 0.5	39.2 ± 6.4	8.34 ± 0.94	32
MOEA/D	1.1983 ± 0.0261	1.1998 ± 0.0263	10.2 ± 2.9	21.4 ± 11.1	0.739 ± 0.067	2

Table 3: Task 2 最终结果汇总（5 seeds, population std）。ND phenotype 数在 phenotype deduplication 后计算。

MOEA/D 的平均 final-population HV 高出 0.01119，约为 NSGA-II 均值的 0.94%。图 Figure 8 保留了 paired design：MOEA/D 在 seeds 1、2、4 上较高，NSGA-II 在 seeds 3、5 上较高。五个差值（NSGA-II – MOEA/D）为 $-0.0454, -0.0577, 0.0537, -0.0339, 0.0274$ ，方向并不一致。




Figure 8: 五个 paired seeds 的最终 population hypervolume。每条灰线连接同一初始 population 下的 NSGA-II 与 MOEA/D。

平均 paired difference 的 bootstrap 95% confidence interval 为 $[-0.0480, 0.0286]$ ，sample-standardized effect 为 -0.229 ，双侧 exact Wilcoxon test 得到 $p = 0.625$ 。五个 pairs 的检验分辨率很低， $p > 0.05$ 也不表示两种算

法等价。当前证据支持“MOEA/D 平均值略高”，无法建立稳定的算法优势。三个 reference points 下的平均 ordering 都是 MOEA/D 略高，因此这一均值方向不依赖主 reference point 的单一选择。

2.2.2 Hypervolume 收敛过程

图 Figure 9 使用 evaluation 20、1,000、5,000 与 10,000 的真实 population snapshots。两种算法共享相同初始 population，因此 evaluation 20 的平均 HV 均为 0.9879。NSGA-II 在 evaluation 1,000 时为 1.1468，高于 MOEA/D 的 1.1382；到 evaluation 5,000 时两者分别为 1.1771 与 1.1762，差距已经很小；最后一个 checkpoint 中 MOEA/D 达到 1.1983，NSGA-II 为 1.1871。




Figure 9: 两种算法的 population hypervolume 收敛曲线。实线为 5-seed mean，阴影为 population std；normalization 与 reference point 对所有 runs 固定。

四个 checkpoints 显示 NSGA-II 的早期 front approximation 更快，MOEA/D 的平均优势出现在后半程。由于中间只保存了两个 checkpoints，图中不能精确确定 crossing evaluation。NSGA-II 的 archive HV 与 final-population HV 几乎相同；MOEA/D 的 archive 平均增加约 0.00153，说明其历史搜索中保存了少量未留在最终 weight slots 中的优质 trade-off points。

2.2.3 最终种群与 phenotype diversity

表 Table 3 中两种算法最明显的差异来自最终解集组成。NSGA-II 的 20 个 population slots 平均保留 19.4 个 nondominated distinct phenotypes，MOEA/D 只有 10.2 个。累计 10,000 次评价中，NSGA-II 每个 run 平均访问 9,817.6 个 unique valid phenotypes，MOEA/D 为 9,181.2 个；对应的累计 phenotype redundancy 分别为 1.76% 与 8.18%。两种算法均没有重复评价 exact genotype，因此该差异来自 decoder 映射与搜索状态的集中。




Figure 10: 搜索过程中的 population phenotype diversity。上图为 unique phenotypes，下图为占比最高的单一 phenotype；实线为 5-seed mean，阴影为 population std。

初始 population 平均有 19.6 个 unique phenotypes。一个 generation/sweep 后，NSGA-II 仍为 19.8，MOEA/D 降至 3.8；evaluation 1,000 时分别为 19.6 与 5.8，evaluation 10,000 时分别为 19.4 与 10.6。MOEA/D 后期能够恢复部分多样性，但最终仍明显低于 NSGA-II。

2.3 实验分析

2.3.1 第二目标是否提供有效的权衡信号

在解释 Pareto front 前，先用独立于正式结果的 layout bank 审计 congestion_top10。该 bank 包含可用的 Task 1 initial layouts、mixed saved-best placements 与额外随机初始布局。135 个 layouts 中 133 个成功解码并对应 133 个 distinct phenotypes。

Audit item	Result
Valid / distinct layouts	133 / 133
Phenotype-deduplicated nondominated layouts	2
HPWL-Congestion Spearman / Kendall	0.6991 / 0.5157
High-quality layouts (lowest-HPWL quartile)	34
High-quality congestion relative range	29.07%
256 × 256 vs. 512 × 512 ranking Spearman	0.99943
n7807 only-net maximum fraction	4.88%

Table 4: congestion_top10 的固定 layout-bank 有效性审计。

HPWL 与 congestion 在该 bank 上具有中等正相关，说明降低 HPWL 时经常也能降低该 proxy；相关系数远低于 1，高质量 HPWL 区域内仍保留 29.07% 的 congestion relative range。256 × 256 与 512 × 512 的排序相关达到 0.99943，指标排序对这一分辨率变化稳定。最高 degree net n7807 有 318 个 pins，但它单独产生的 congestion 最多只占完整指标的 4.88%，移除它后的 ranking Spearman 仍为 0.99933。




Figure 11: 归一化目标空间。左：两种算法五个 seeds 的最终 phenotype-deduplicated fronts；右：Task 2 common front 与现有 Task 1 mixed saved-best reference。两个目标均越低越好。

图 Figure 11 左侧显示正式搜索形成了连续的 HPWL-congestion trade-off。各 run 访问区域中的 phenotype-deduplicated nondominated 数量为 56-236；HPWL-Congestion Spearman 随 seed 与算法在 -0.448 到 0.720 之间变化。第二目标在当前 audited/visited regions 中提供了可区分的局部选择信号。

2.3.2 Phenotype redundancy 与 MOEA/D collapse

MOEA/D 的多样性损失在第一个完整 sweep 就出现。每个 seed 的 20 个初始 weight slots 都对应 19 或 20 个 distinct phenotypes；evaluation 40 时平均只剩 3.8 个，单一 phenotype 恰好占 50% slots。五个 seeds 的 first_half_population_collapse_sweep 均为 1。




Figure 12: MOEA/D weight-slot occupancy。细线表示单个 seed，粗线表示 5-seed mean；横轴使用对数尺度，虚线对应第一个完整 sweep。

最严重的 seed 曾由一个 phenotype 占据全部 20 个 slots；其他 seeds 的最大集中比例为 60%-75%。evaluation 10,000 时，五个 runs 分别恢复到 7、7、14、11、14 个 slot phenotypes，最大单一 phenotype 比例仍为 15%-40%。所有 runs 的 historical ideal point 均保持 component-wise non-regression，因此 collapse 与 ideal-point 更新错误无关。当前 MOEA/D 允许一个 offspring 同时替换所有改善的邻居；在 population size 为 20、neighborhood size 为 10 时，早期优质 offspring 可以迅速复制到多个相邻 weight directions。该机制与 slot-state trace 一致，但本文没有通过 replacement-cap ablation 验证独立因果效应。

MOEA/D 最终平均 HV 略高，说明 slot concentration 在本实验中没有阻止二维 HV 的继续改善；它显著减少了最终 phenotype 数，并提高了 seed 对历史搜索路径的依赖。若 Task 3 关注稳定、多样的 Pareto set，weight-slot diversity 是比继续增加评价预算更直接的干预对象。

2.3.3 Uniform + Swap 的实际扰动及其后果

Task 1 对 Uniform + Swap 的解释主要来自最终性能。Task 2 的 per-evaluation trace 可以直接比较 offspring 与两个父代解码后的 placement。图 Figure 13 将每个 parent-child comparison 按实际移动宏数分组；rate 按每组 comparison 数量跨 seeds 加权。




Figure 13: 按相对父代的实际移动宏数量分组后的 offspring survival 与 dominated-by-parent rate。数值按 parent-child comparisons 加权。

NSGA-II 中，移动 1-10、11-100、超过 100 个宏的 offspring survival rate 分别为 58.8%、30.7% 与 5.3%；被相应父代支配的比例从 7.7% 上升到 43.0% 与 59.0%。MOEA/D 的同三组 survival rate 为 7.5%、10.3% 与 5.6%，dominated rate 为 7.8%、35.3% 与 56.0%。超过 100 个宏的大范围 placement change 在两个算法中都更容易破坏已有 trade-off structure。

零位移 offspring 在 NSGA-II 中仍有 60.9% 被标记为 survivor，MOEA/D 中为 4.5%。这里的 survivor 表示 offspring object 是否保留在算法状态中；NSGA-II 的 rank/crowding survival 可以保留 objective-identical individuals，而 MOEA/D 只有改善 decomposition value 才执行 replacement，因此两者的绝对 survival rate 不能解释为 variation 本身的质量差异。

累计 trace 中，NSGA-II offspring 相对父代改善 HPWL 与 congestion 的比例平均高于 MOEA/D，但两种算法使用了不同 parent selection 和 survivor semantics。现有数据能够描述 combined Uniform-plus-Swap pipeline 的实际 phenotype effect，无法分离 Uniform crossover 与 Swap mutation 的独立贡献。

2.3.4 与 Task 1 参考结果的比较

可用的 Task 1 历史 artifacts 没有保存五个 Uniform + Swap runs 的完整 final populations，也没有中间 population snapshots。当前 reference 由 15 个 mixed saved-best distinct phenotypes 构成，覆盖多个可用 Task 1 formal/smoke runs；它适合作为已有单目标结果的有限参照，不能代表某个算子组合的完整最终解集。

该 reference 在 Task 2 两个目标下只有 1 个 nondominated point，其 HV 为 1.1113。Task 2 十个 final populations 的 pooled common front 含 23 个 points，HV 为 1.2502；Task 1 的 nondominated reference point 被 Task 2 front 支配，Task 2 front 没有 point 被该 Task 1 point 支配。合并 front 的 23 个贡献全部来自 Task 2，如图 Figure 11 右侧所示。

多目标搜索扩展了现有 Task 1 saved-best reference，并找到了同时具有更低 utilization proxy 的高质量布局。由于 reference scope 不完整，本文不声称 Task 2 覆盖了 Task 1 Uniform + Swap 的完整 final populations。

2.3.5 对 Task 3 的启示

Task 2 给出了三组可以直接指导 Task 3 的证据：

1. NSGA-II 的早期 HV 上升更快，最终维持接近满 population 的 distinct phenotypes；MOEA/D 的平均最终 HV 略高，但 paired differences 对 seed 敏感。
2. MOEA/D 在第一个 sweep 发生系统性的 slot collapse，后期只能部分恢复。限制单个 offspring 的邻域 replacement、维护 phenotype-aware occupancy 或增加适度的 diversity pressure 都有明确的数据动机。

3. Uniform + Swap 能产生大量实际 placement changes；超过 100 个宏的大范围变化通常具有较低 survival 和较高 dominated rate。Task 3 可以优先考虑 decoder-aware、位移受控的 variation，并通过独立 ablation 判断收益来自扰动尺度还是新的结构信息。

当前 Task 2 在一个 top-512 macro 实例上建立了受控 baseline 与机制诊断。完整 543-macro adaptec1、其他 benchmarks、真实 global-routing congestion、Shift 的早停机制、Lamarckian write-back、invalid repair 和完整 operator factorial 均需要新的实验设计，现有 trace 不足以支持这些外推。

3 Task 3：改进算法

3.1 结果分析

尚无正式结果。

4 实验框架捉 bug

4.1 Bug 1: MGO net traversal 非确定性

原实现通过无序集合构造 macro-to-net mapping, 导致 net traversal 顺序可能随 Python hash 状态或输入插入顺序变化。由于 MGO 的 greedy placement 会逐步更新 wire mask, 遍历顺序变化可能改变 phenotype 与 HPWL, 并在并发环境中表现为难以复现的差异。修复后对 net 名称排序并存为不可变 tuple, 同时增加输入顺序反转测试。详见 [PR 12](#)。

4.2 Bug 2: 初始化 population 被重复评价

Sampling 已经评价全部初始候选并选出保留个体, 但原接口只向 pymoo 返回 x , 导致保留的初始 population 再被评价一次。这样既浪费真实预算, 也使 pymoo 计数与 placer 真实计数不一致。修复后 Sampling 返回包含 X 、 F 、 $overlap_rate$ 和 $macro_pos$ 的 Population, 并正确标记已知评价字段。详见 [PR 13](#)。

4.3 Bug 3: Swap mutation 的高级索引错误

原 Swap 使用二维高级索引在整个 batch 上采样和赋值, 无法保证每个 individual 独立选择两个 macro, 且赋值广播语义可能破坏预期交换。修复后逐 individual 无放回采样两个 macro index, 并同时交换完整的 (x, y) coordinate pair; 输入数组保持不变。详见 [PR 13](#)。

4.4 Bug 4: DummyMutation 初始化与约束字段标记

DummyMutation 原先调用了另一个 mutation class 的 super, 实例化即可触发错误。修复后使用本类正确的 `super().__init__`。此外, Sampling 不再无条件将 G、H 标记为已评价, 而是仅在问题不存在对应约束时标记, 避免约束问题被错误跳过。相关回归测试覆盖 no-op 行为、评价预算和约束字段。详见 [PR 13](#)。

5 附录

5.1 Task 1 运行与复现

运行:

```
python experiments/run_task1.py formal \  
--python=/home/sihengzhao/t1/env/bin/python \  
--workers=8 \  
--cpus-per-run=12
```

在我的实际配置上, 每个 run 在独立进程与独立 Ray 临时目录中执行, 设置 `OMP_NUM_THREADS=1`、`MKL_NUM_THREADS=1`、`OPENBLAS_NUM_THREADS=1`、`CUDA_VISIBLE_DEVICES=""` 和 `PYTHONHASHSEED=seed`。调度上限为 8 个并发 runs、每 run 12 CPU、总上限 96 logical CPUs, 并以 `nice -n 10` 降低对共享服务器的影响。正式套件总耗时 32,546 s, 即约 9 h 02 min 26 s。

结果目录包含:

```
results/adaptecl/task1_formal__*/mgo/ea/seed_*/  
  evaluation_trace.csv  
  generation_metrics.csv  
  metrics.csv  
  initial_population.npz  
  initial_population_hash.json  
  resolved_config.yaml  
  runtime_metadata.json  
  run_complete.json  
  placements/  
  figures/
```

分析命令与报告图命令为:

```
python experiments/analyze_task1.py  
python experiments/render_task1_report.py \  
--output-dir experiments/task1_analysis/report_figures
```

5.2 Task 2 运行与复现

Task 2 的环境安装与激活脚本为:

```
bash script/setup_task2_remote_env.sh  
source script/task2_remote_env.sh
```

正式运行前, `run_task2.py` 会读取冻结协议、自动生成 smoke decision, 并验证 benchmark、代码、环境、DREAMPlace binary 与 experiment definition fingerprints。正式命令为:

```
python3 experiments/run_task2.py --mode formal
```

正式 scheduler 使用 CPU backend、2 个并发 runs、每 run 20 logical CPUs、`rudycpu_threads = 1`、`nice = 10`, 并为其他用户保留至少 32 个 logical CPUs。10 个 runs 均完成 10,000 次真实评价, 总计 100,000 次。最早 run 于 2026-07-24 15:29:20 UTC 启动, 最后 run 于 2026-07-25 03:47:17 UTC 完成, formal suite wall time 为 44,276.8 s, 即约 12 h 17 min 57 s。所有 runs 的累计进程时间为 74,275.5 s; 两者不同是因为 scheduler 同时运行两个独立实验。

正式结果位于:

```
experiments/task2_runs/formal/  
  summary.json  
  seed_*__nsga2.json  
  seed_*__moea.json  
  seed_*__*.log  
  
results/adaptecl/task2_formal__*/mgo/task2_moea/seed_*/  
  evaluation_trace.csv  
  generation_metrics.csv  
  final_population.npz  
  offline_archive.npz  
  population_snapshots/  
  moead_state.csv          # MOEA/D only
```

```
initial_population.npz
initial_population_hash.json
placedb_fingerprint.json
resolved_config.yaml
runtime_metadata.json
run_complete.json
```

分析和报告绘图命令与 Task 1 对称:

```
python3 experiments/analyze_task2.py
python3 experiments/render_task2_report.py \
  --output-dir assets/task2
```

分析结果写入 `experiments/task2_analysis/`, 包括 `final/archive HV`、`paired differences`、`convergence`、`phenotype diversity`、`MOEA/D slot occupancy`、`displacement-conditioned outcomes` 与 Task 1 coverage。绘图脚本同时生成 PNG 和 PDF, 并写出 `assets/task2/figure_manifest.csv`。

正式 run 使用 commit 5bbbd42 对应的 code fingerprint `bd58e94c...bac5` 与 environment fingerprint `af9633bb...9e5dd`。后续对 fingerprint postprocessing 与报告导出的修正没有重新评价任何 genotype, 也没有改变原始 formal results。

5.3 Task 3 运行结果、复现方法与运行时间

尚未产生正式结果。